

Statistiques Descriptives avec R

Christophe Ambroise

2025-03-12

Table des matières

Préface	3
1 Langage R	4
2 Outils de rédaction et d'analyse reproductible	9
3 Statistiques avec R: les bases	14

Préface

Ce livret propose des exercices et leurs solutions pour le cours ‘Statistiques descriptives avec R’.

1 Langage R

Exercice 1.1. Types

Dans cet exercice, nous allons utiliser les trois types de variables disponibles dans R :

1. Créer deux variables booléennes (TRUE, FALSE) et tester toutes les opérations logiques.
2. Utiliser R comme une calculatrice pour calculer et stocker dans une variable la moyenne des notes suivantes :

10, 11, 15, 16, 21

3. Manipuler une chaîne de caractères : transformer la chaîne “Statistiques descriptives avec R” en séparant tous les mots.

Solution 1.1.

```
# 1. Opérations logiques avec des booléens
a <- TRUE
b <- FALSE
a | b # OU logique
```

```
[1] TRUE
```

```
a & b # ET logique
```

```
[1] FALSE
```

```
# 2. Calcul de la moyenne
notes <- c(10, 11, 15, 16, 21)
moyenne <- mean(notes)
moyenne # Affichage du résultat
```

```
[1] 14.6
```

```
# 3. Manipulation de texte
phrase <- "Statistiques descriptives avec R"
mots <- strsplit(phrase, " ")
mots  # Affichage des mots séparés
```

```
[[1]]
[1] "Statistiques" "descriptives" "avec"          "R"
```

Exercice 1.2. Génération de Vecteurs

Dans cet exercice, nous allons nous familiariser avec la création de vecteurs en R en utilisant les commandes `c()`, `seq()`, `rep()`, `paste()` et leurs options.

1. Créer un vecteur contenant la suite des entiers de 1 à 12 de deux manières différentes.
2. Créer le vecteur

```
c(0.5,1.0,1.5,2.0,2.5,3.0,3.5,4.0,4.5,5.0)
```

de trois manières différentes.

3. Créer un vecteur contenant tous les multiples de 2 compris entre 1 et 50.
4. Créer un vecteur contenant tous les nombres de 1 à 100 qui ne sont pas des multiples de 5.
5. Créer un vecteur contenant 3 fois chacun des 10 chiffres.
6. Créer un vecteur contenant une fois la lettre A, deux fois la lettre B,..., 26 fois la lettre Z. Quelle est la longueur de cette suite ? (Utiliser la chaîne `LETTERS` prédéfinie).
7. Créer le vecteur suivant :

```
c("individu 1", "individu 2", ..., "individu 100")
```

Solution 1.2. Génération de Vecteurs

```
# 1. Suite des entiers de 1 à 12 de deux manières différentes
v1 <- c(1:12)
v2 <- seq(1, 12, by=1)

# 2. Vecteur avec valeurs décimales de trois manières différentes
v3_1 <- c(0.5,1.0,1.5,2.0,2.5,3.0,3.5,4.0,4.5,5.0)
v3_2 <- seq(0.5, 5.0, by=0.5)
v3_3 <- (0:9) / 2 + 0.5

# 3. Tous les multiples de 2 entre 1 et 50
```

```

v4 <- seq(2, 50, by=2)

# 4. Tous les nombres de 1 à 100 qui ne sont pas des multiples de 5
v5 <- (1:100)[(1:100) %% 5 != 0]

# 5. 3 fois chacun des 10 chiffres
v6 <- rep(0:9, each=3)

# 6. Une fois A, deux fois B, ..., 26 fois Z
v7 <- rep(LETTERS, times=1:26)
longueur_v7 <- length(v7) # Longueur de la séquence

# 7. Vecteur avec "individu 1" à "individu 100"
v8 <- paste("individu", 1:100)

# Affichage des résultats
list(v1, v2, v3_1, v3_2, v3_3, v4, v5, v6, v7, longueur_v7, v8)

```

Exercice 1.3. Comptage

Ecrire un code R qui génère un échantillon $(x_1, \dots, x_{100})$ de loi parente $\mathcal{N}(0, 2)$:

1. compter le nombre de réalisations supérieures à 1.
2. donner l'effectif théorique de réalisations supérieures à 1.

Solution 1.3. Comptage

Version vectorielle

```

set.seed(3)
sum(rnorm(100, mean=0, sd=2) > 1)

```

```
[1] 32
```

```
(1-pnorm(1, sd=2))*100
```

```
[1] 30.85375
```

D'un point de vue effectif théorique, nous nous attendons à avoir $100.P(X > 1)$: 30.8537539

Version boucle

```

set.seed(3)
x<-rnorm(100,mean=0,sd=2)
compteur<-0
for (i in 1:100)
  if (x[i]>1) compteur<-compteur+1
print(compteur)

```

[1] 32

Exercice 1.4. Résumé de Texte

Écrire une série d'instructions R qui résume l'extrait suivant de Wikipedia :

La statistique est d'un point de vue théorique une science, une méthode et une technique. La statistique comprend : la collecte des données, le traitement des données collectées, l'interprétation des données, la présentation afin de rendre les données compréhensibles par tous. Remarquons que la statistique est parfois notée « la Statistique » (avec une majuscule) ce qui permet de différencier cette science avec une statistique (avec une minuscule). Le pluriel est également souvent utilisé pour désigner ce domaine mathématique : « les statistiques », cela permet de montrer la diversité de cette science ; le pluriel est utilisé en anglais. Ainsi la statistique est un domaine des mathématiques qui possède une composante théorique ainsi qu'une composante appliquée. La composante théorique est proche de la théorie des probabilités et forme avec cette dernière, les sciences de l'aléatoire. La statistique appliquée est utilisée dans presque tous les domaines de l'activité humaine : ingénierie, management, économie, biologie, informatique, etc. La statistique utilise des règles et des méthodes sur la collecte des données, pour que celles-ci puissent être correctement interprétées, souvent comme composante d'une aide à la décision. Le statisticien a pour profession la mise au point d'outils statistiques, dans le secteur privé ou le secteur public, et leur exploitation généralement dans un domaine d'expertise.

Une approche rapide consiste à prendre la première et la dernière phrase de cet extrait.

Solution 1.4.

```

options(width = 60)
# Définition du texte initial
MonTexte <- "La statistique est d'un point de vue théorique une science,
une méthode et une technique. La statistique comprend : la collecte des données,
le traitement des données collectées, l'interprétation des données, la présentation

```

afin de rendre les données compréhensibles par tous.
 Remarquons que la statistique est parfois notée
 « la Statistique » (avec une majuscule) ce qui permet
 de différencier cette science avec une statistique
 (avec une minuscule). Le pluriel est également souvent
 utilisé pour désigner ce domaine mathématique :
 « les statistiques », cela permet de montrer la diversité de cette science ;
 le pluriel est utilisé en anglais.
 Ainsi la statistique est un domaine des mathématiques qui possède
 une composante théorique ainsi qu'une composante appliquée.
 La composante théorique est proche
 de la théorie des probabilités et forme avec cette dernière,
 les sciences de l'aléatoire. La statistique
 appliquée est utilisée dans presque tous les domaines de l'activité humaine :
 ingénierie, management,
 économie, biologie, informatique, etc.
 La statistique utilise des règles et des méthodes sur la collecte
 des données, pour que celles-ci puissent être correctement interprétées,
 souvent comme composante
 d'une aide à la décision. Le statisticien a pour profession
 la mise au point d'outils statistiques, dans le
 secteur privé ou le secteur public, et leur exploitation
 généralement dans un domaine d'expertise."

```
# Fonction pour extraire le résumé
resume <- function(MonTexte) {
  phrases <- unlist(strsplit(MonTexte, split = "\\.\ "))
  cat(paste(phrases[1], " ...", phrases[length(phrases)], sep = ""))
}

# Résumé du texte
resume(MonTexte)
```

La statistique est d'un point de vue théorique une science,
 une méthode et une technique ...Le statisticien a pour profession
 la mise au point d'outils statistiques, dans le
 secteur privé ou le secteur public, et leur exploitation
 généralement dans un domaine d'expertise.

2 Outils de rédaction et d'analyse reproductible

Exercice 2.1. Ecire un document minimal qui permette de produire un fichier html, word, beamer, pdf, powerpoint.

Solution 2.1.

```
---
title: "Exercice série 1"
output:
  pdf_document:
    toc: true
  beamer_presentation: default
  html_document:
    toc: true
    toc_float: true
  word_document: default
  powerpoint_presentation: default
date: "2025-03-14"
---
```

Exercice 2.2. Rédaction d'un document Quarto pour résoudre une équation quadratique

1. Commencez le document avec une introduction expliquant l'objectif de résoudre l'équation quadratique suivante :

$$x^2 - 5x + 6 = 0$$

2. Résolvez l'équation en détaillant les étapes mathématiques.
3. Vérifiez la solution numérique de l'équation en utilisant R ou Python.
4. Enregistrez le document sous le format HTML et PDF.

Solution 2.2.

Listing 2.1 Code yaml

```
---
title: "Résolution d'une équation quadratique"
author: "Étudiant"
date: today
format:
  html: default
  pdf: default
lang: fr
---
```

Listing 2.2 Code markdown

Introduction

Dans ce document, nous allons résoudre l'équation quadratique suivante :

$$x^2 - 5x + 6 = 0$$

Nous utiliserons la formule du discriminant et vérifierons les solutions en Python.

Résolution mathématique

L'équation quadratique standard est donnée par :

$$ax^2 + bx + c = 0$$

Ici, nous avons $a = 1$, $b = -5$ et $c = 6$.

Le discriminant est :

$$\Delta = b^2 - 4ac = (-5)^2 - 4(1)(6) = 25 - 24 = 1$$

Les solutions sont données par :

$$x = \frac{-b \pm \sqrt{\Delta}}{2a}$$

En remplaçant les valeurs :

$$x_1 = \frac{5 + 1}{2} = \frac{6}{2} = 3$$

$$x_2 = \frac{5 - 1}{2} = \frac{4}{2} = 2$$

Les solutions sont $x = 2$ et $x = 3$.

Vérification en Python

Nous pouvons confirmer ces solutions en utilisant Python :

Listing 2.3 Code python

```
```python
#| eval: true
#| include: true
Définition des coefficients de l'équation $ax^2 + bx + c = 0$
a = 1
b = -5
c = 6

Calcul du discriminant $\Delta = b^2 - 4ac$
delta = b * b - 4 * a * c

Résolution en fonction de la valeur de Δ
if delta > 0:
 x1 = (-b + (delta ** 0.5)) / (2 * a) # $\sqrt{\Delta}$ est remplacé par $** 0.5$
 x2 = (-b - (delta ** 0.5)) / (2 * a)
 solutions = [x1, x2]
elif delta == 0:
 x1 = -b / (2 * a) # Cas où $\Delta = 0$, une seule solution
 solutions = [x1]
else:
 solutions = ["Pas de solution réelle"]

Affichage des solutions
print(solutions)
```
```

Listing 2.4 Code R

```
``r

#| eval: true
#| include: true

# Définition des coefficients de l'équation  $ax^2 + bx + c = 0$ 
a <- 1
b <- -5
c <- 6

# Calcul du discriminant  $\Delta = b^2 - 4ac$ 
delta <- b * b - 4 * a * c

# Résolution en fonction de la valeur de  $\Delta$ 
if (delta > 0) {
  x1 <- (-b + sqrt(delta)) / (2 * a) #  $\sqrt{\Delta}$  est calculé avec sqrt()
  x2 <- (-b - sqrt(delta)) / (2 * a)
  solutions <- c(x1, x2)
} else if (delta == 0) {
  x1 <- -b / (2 * a) # Cas où  $\Delta = 0$ , une seule solution
  solutions <- c(x1)
} else {
  solutions <- "Pas de solution réelle"
}

# Affichage des solutions
print(solutions)

``
```

3 Statistiques avec R: les bases

Exercice 3.1. Utilisation d'un type de distribution

Illustrer avec la loi normale, les quatre fonctions R:

- `rnorm` simulation
- `dnorm` densité
- `pnorm` fonction de répartition
- `qnorm` quantile

Solution 3.1. Simulation et histogramme

```
library(ggplot2)

# Set seed for reproducibility
set.seed(123)


# Parameters for the normal distribution
mean <- 0
sd <- 1

# Generate a sample
x <- rnorm(100, mean = mean, sd = sd)

# Create a data frame for ggplot2
data <- data.frame(x = x)

# Plot histogram using ggplot2
ggplot(data, aes(x = x)) +
  geom_histogram(binwidth = 0.5, fill = "skyblue", color = "black", alpha = 0.7) +
  labs(title = "Histogram of Normally Distributed Random Numbers",
       x = "Value",
       y = "Frequency") +
  theme_minimal()
```

Histogram of Normally Distributed Random Numbers



Densité, fonction de répartition et quantile

```
# Generate x values
x_vals <- seq(-4, 4, length.out = 100)

# Compute PDF and CDF values
pdf_values <- dnorm(x_vals, mean = mean, sd = sd)
cdf_values <- pnorm(x_vals, mean = mean, sd = sd)


# Normalize CDF values to be on a similar scale as PDF
cdf_values_normalized <- cdf_values / max(cdf_values) * max(pdf_values)

# Compute the 80th percentile quantile
quantile_80 <- qnorm(0.8, mean = mean, sd = sd)

# Create a data frame for ggplot2
data <- data.frame(
  x = x_vals,
  pdf = pdf_values,
  cdf_normalized = cdf_values_normalized
)

# Plot using ggplot2
ggplot(data, aes(x = x)) +
```

```
geom_line(aes(y = pdf, color = "PDF"), linewidth = 1) +
geom_line(aes(y = cdf_normalized, color = "Normalized CDF"), linetype = "dashed", linewidth = 1) +
geom_vline(xintercept = quantile_80, linetype = "dotted", color = "black", linewidth = 1) +
annotate("text", x = quantile_80 + 0.3, y = 0.02, label = "80th Percentile", color = "black") +
labs(title = "Normal Distribution (PDF and Normalized CDF)",
     x = "X",
     y = "Density / Normalized CDF") +
scale_color_manual(name = "Legend", values = c("PDF" = "blue", "Normalized CDF" = "red")) +
theme_minimal()
```



Exercice 3.2. Loi normale et écart à la moyenne

Soit $X \sim \mathcal{N}(\mu, \sigma^2)$. Calculer la probabilité que

$$P(X \in [\mu - k\sigma, \mu + k\sigma]),$$

pour $k \in \{1, 2, 3, 4\}$.

Solution 3.2.

$$P(X \in [\mu - k\sigma, \mu + k\sigma]) = P(X \leq \mu + k\sigma) - P(X \leq \mu - k\sigma) \quad (3.1)$$

$$= P\left(\frac{X - \mu}{\sigma} \leq k\right) - P\left(\frac{X - \mu}{\sigma} \leq -k\right) \quad (3.2)$$

$$= \phi(k) - \phi(-k) \quad (3.3)$$

$$= 2\phi(k) - 1 \quad (3.4)$$

```
library(knitr)
tableau=data.frame(k=1:4,Pk=2*pnorm(1:4)-1)
tableau_transpose <- as.data.frame(t(tableau))
colnames(tableau_transpose) <- paste0("k=", tableau$k)
tableau_transpose <- cbind(Variable = rownames(tableau_transpose), tableau_transpose)
rownames(tableau_transpose) <- NULL

# Affichage avec kable
kable(tableau_transpose, caption = "Tableau transposé de k et Pk")
```

Table 3.1: Tableau transposé de k et Pk

| Variable | k=1 | k=2 | k=3 | k=4 |
|----------|-----------|-----------|-----------|-----------|
| k | 1.0000000 | 2.0000000 | 3.0000000 | 4.0000000 |
| Pk | 0.6826895 | 0.9544997 | 0.9973002 | 0.9999367 |

Exercice 3.3. Estimation du poids moyen des nouveau-nés

Une maternité a enregistré le poids de **100 bébés** nés à terme. Ces poids sont modélisés par une variable aléatoire suivant une **loi normale** de moyenne (= 3.3) kg et d'écart-type (= 0.5) kg.

Dans le cadre de cette étude, trois valeurs **atypiques** (outliers) ont été malencontreusement ajoutées à l'échantillon : **2000 kg, 3000 kg et 3500 kg**.

Objectifs

- Estimer la **moyenne empirique** et l'**écart-type empirique** de l'échantillon **avec** et **sans** les valeurs aberrantes.
- Visualiser l'effet des outliers sur les estimations et sur l'histogramme des poids.

Simulation des données

```
set.seed(42)
poids <- rnorm(100, mean = 3.3, sd = 0.5)
poids_outliers <- c(poids, 2000, 3000, 3500)
```

Solution 3.3. Fonctions robustes pour moyenne et écart-type tronqués

```
# Fonction pour la moyenne tronquée (trimmed mean)
mean.trimmed <- function(x, alpha = 0.2) {
  borne.inf <- quantile(x, probs = alpha / 2)
  borne.sup <- quantile(x, probs = 1 - alpha / 2)
  normal <- (x > borne.inf) & (x < borne.sup) # Sélection des données non extrêmes
  x.trimmed <- x[normal]                    # Échantillon tronqué
  return(mean(x.trimmed))
}

# Fonction pour l'écart-type tronqué
sd.trimmed <- function(x, alpha = 0.2) {
  borne.inf <- quantile(x, probs = alpha / 2)
  borne.sup <- quantile(x, probs = 1 - alpha / 2)
  normal <- (x > borne.inf) & (x < borne.sup)
  x.trimmed <- x[normal]
  return(sd(x.trimmed))
}
```

Estimation des moyennes et écarts-types

```
# Moyenne et écart-type classiques (sans valeurs aberrantes)
mean_sans <- mean(poids)
sd_sans <- sd(poids)

# Moyenne et écart-type classiques (avec valeurs aberrantes)
mean_avec <- mean(poids_outliers)
sd_avec <- sd(poids_outliers)

# Moyenne et écart-type robustes (avec valeurs aberrantes)
mean_trimmed <- mean.trimmed(poids_outliers)
sd_trimmed <- sd.trimmed(poids_outliers)

# Tableau récapitulatif
moyennes <- data.frame(
```

```

Cas = c("Sans valeurs aberrantes", "Avec valeurs aberrantes", "Robuste (tronqué)",
Moyenne = c(mean_sans, mean_avec, mean_trimmed),
Ecart_type = c(sd_sans, sd_avec, sd_trimmed)
)

# Affichage tableau ggplot
library(ggplot2)
library(tidyr)
library(dplyr)

```

Attaching package: 'dplyr'

The following objects are masked from 'package:stats':

filter, lag


The following objects are masked from 'package:base':

intersect, setdiff, setequal, union

```

donnees_long <- pivot_longer(moyennes, cols = c(Moyenne, Ecart_type), names_to = "Mesure", v
ggplot(donnees_long, aes(x = Cas, y = Valeur, fill = Mesure)) +
  geom_col(position = "dodge") +
  labs(title = "Comparaison des estimations classiques et robustes",
       y = "Valeur estimée", x = NULL) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 20, hjust = 1))

```



Analyse

- L'ajout des **valeurs aberrantes** modifie beaucoup la moyenne et l'écart-type classiques sur notre expérience.
- Les estimations **robustes** (moyenne et écart-type tronqués) sont **moins sensibles** aux valeurs extrêmes.
- Cela illustre l'intérêt de méthodes robustes en présence de données bruitées ou atypiques.
- Ces techniques sont utiles en pratique pour fournir une **meilleure estimation centrale** lorsque l'on suspecte la présence de perturbations dans les données.